

# Pruba HDI

## Max Benjamín Austria Salazar

- El objetivo es crear un modelo de regresión adecuado para la Frecuencia, y otro para la Severidad, utilizando algunas de las variables compartidas como variables explicativas.

$$Frecuencia = \frac{NumSiniestros}{UnidadesExpuestas}$$

$$Severidad = \frac{MontoOcurrido}{NumSiniestros}$$

$$Precio = Frecuencia * Severidad$$

- Como entregable hay que proporcionar el código para generar dichos modelos, la validación con las métricas respectivas,
- y por último, la tabla con la predicción de la Frecuencia y Severidad para cada uno de los registros.
- Hay que añadir la columna de Precio, multiplicando las predicciones de Frecuencia y Severidad respectivamente

## Paquetes

In [445...

```
#Para las gráficas
library(dplyr)
library(ggplot2)
library(ggfortify)
library(ranger)
library(ggpubr)
library(lattice)

#Para el análisis
library(glmmTMB)#Otra opción es Rfast2
#library(statmod)
```

Attaching package: ‘glmmTMB’

The following object is masked from ‘package:statmod’:

tweedie

## Cargando los datos

In [141...

```
#Carga de los datos
datos <- readr::read_csv(file = "datos.csv", locale = readr::locale(encoding = "ISO-8859-1"))

#Formateando
datos$Anio = as.factor(datos$Anio)
datos$ID = as.character(datos$ID)
datos$NombreSubdireccion = as.factor(datos$NombreSubdireccion)
datos$DescTipoVehiculo = as.factor(datos$DescTipoVehiculo)
datos$TipoPersona = as.factor(datos$TipoPersona)
datos$Edad = as.integer(datos$Edad)
datos$Sexo = as.factor(datos$Sexo)
datos$DescMarcaVehiculo = as.factor(datos$DescMarcaVehiculo)
datos$DescCarroceriaVehiculo = as.factor(datos$DescCarroceriaVehiculo)
datos$ModeloVehiculo = as.integer(datos$ModeloVehiculo)
datos$DescUsoVehiculo = as.factor(datos$DescUsoVehiculo)
```

```
#datos$UnidadesExpuestas = abs(datos$UnidadesExpuestas)

#Ejemplo
head(datos)
```

Rows: 50000 Columns: 16  
— Column specification  
Delimiter: ", "  
chr (7): NombreOficina, NombreSubdireccion, DescTipoVehiculo, TipoPersona, D...  
dbl (9): Anio, ID, UnidadesExpuestas, Edad, Sexo, ModeloVehiculo, PrimaNetaP...  
  
i Use `spec()` to retrieve the full column specification for this data.  
i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

Anio	ID	NombreOficina	UnidadesExpuestas	NombreSubdireccion	DescTipoVehiculo	TipoPersona
<int>	<chr>	<chr>	<dbl>	<fct>	<fct>	<fct>
2021	40480000012367	048 Cruz Promotores	0.0000000	Promotorias Guadalajara	Vehiculos Residentes	Fisica
2020	42730000831079	273 Morris	0.0000000	Noroeste	Pick Up	Fisica
2021	40100001237795	010 Queretaro	0.0000000	Centro	Vehiculos Residentes	Fisica
2019	40740000829763	074 Telemarketing Corporativo	0.1589041	Telemarketing	Pick Up	Fisica
2019	40980000054921	098 Abs Actuarios Consultores Sociedad Civil	0.3287671	Promotorias México Sur	Vehiculos Residentes	Fisica
2021	40570001238666	057 Mochis	0.9698630	Noroeste	Vehiculos Residentes	Fisica

## Estadística Descriptiva

Estadística descriptiva entre las variables: MontoOcurrido, NumSiniestros, UnidadesExpuestas.

In [142...

```
col = which(colnames(datos) %in% c("MontoOcurrido", "NumSiniestros", "UnidadesExpuestas"))
cor(datos[,col])
```

A matrix: 3 × 3 of type dbl

	UnidadesExpuestas	MontoOcurrido	NumSiniestros
UnidadesExpuestas	1.00000000	0.07868049	0.2084499
MontoOcurrido	0.07868049	1.00000000	0.3500598
NumSiniestros	0.20844989	0.35005984	1.0000000

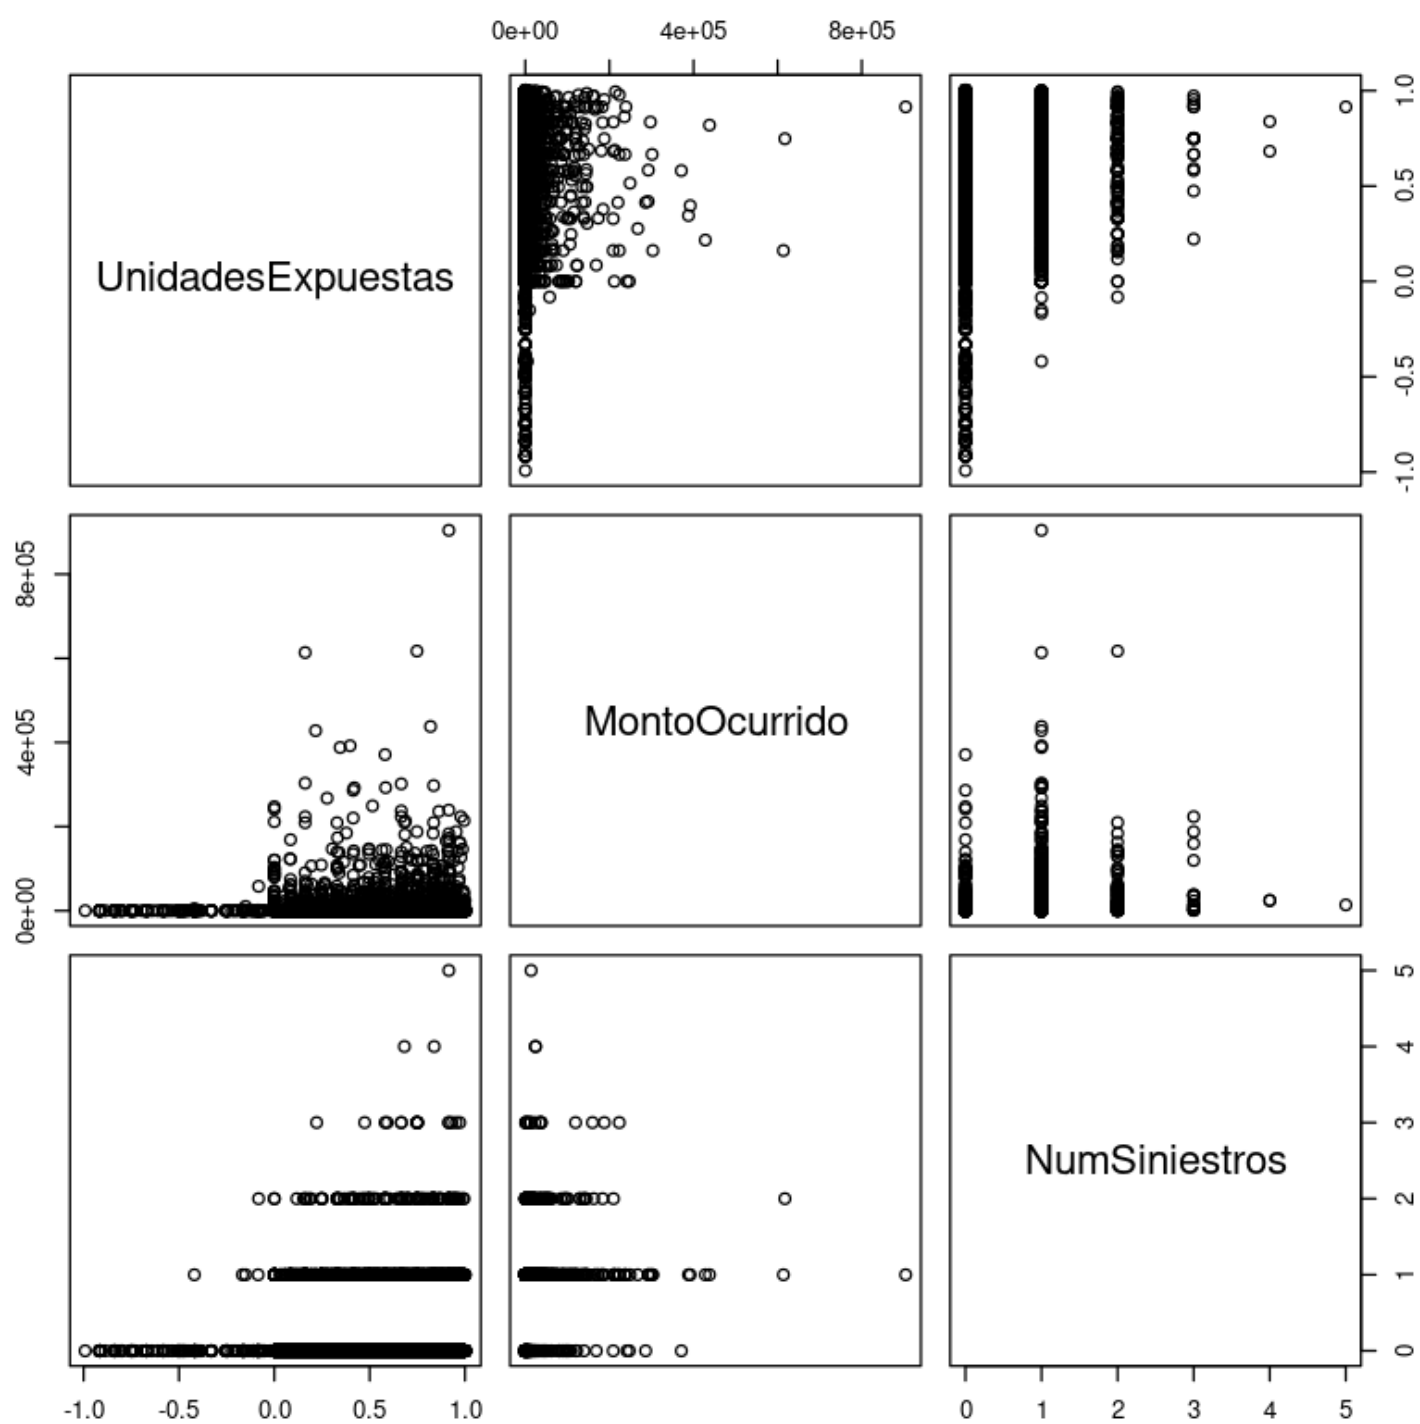
In [143...

```
summary(datos[,col])
```


UnidadesExpuestas	MontoOcurrido	NumSiniestros
Min. : -0.99178	Min. : 0.0	Min. : 0.00000
1st Qu.: 0.00000	1st Qu.: 0.0	1st Qu.: 0.00000
Median : 0.09041	Median : 0.0	Median : 0.00000
Mean : 0.25217	Mean : 828.6	Mean : 0.03916
3rd Qu.: 0.48219	3rd Qu.: 0.0	3rd Qu.: 0.00000
Max. : 1.00274	Max. : 904414.3	Max. : 5.00000

In [144...

```
options(repr.plot.width = 7, repr.plot.height = 7)
plot(datos[,col])
```



```
In [145... hist(datos$UnidadesExpuestas, main ="UnidadesExpuestas", breaks = 25)
```



Observación.

Hay valores negativos en variables que (en principio) deberían ser positivas. Por ahora voy a trabajar con el valor absoluto, pues considero que el signo debe ser por algún tema contable.

```
In [146... col = which(colnames(datos) %in% c("UnidadesExpuestas","PrimaNetaPropiaSinCoaseguro"))
datos[which(datos$UnidadesExpuestas<0),col]
```

A tibble: 207 × 2

UnidadesExpuestas	PrimaNetaPropiaSinCoaseguro
<dbl>	<dbl>
-0.076712329	-711.0069

UnidadesExpuestas	PrimaNetaPropiaSinCoaseguro
<dbl>	<dbl>
-0.052054795	-1733.8314
-0.249315069	0.0000
-0.084931507	-1872.4415
-0.471232878	-874.9088
-0.016438356	-109.1596
-0.504109590	-698.6279
-0.394520549	-821.0379
-0.419178083	-3269.4355
-0.161643836	0.0000
-0.495890412	0.0000
-0.169863014	-502.9333
-0.161643836	0.0000
-0.693150686	-1074.9416
-0.753424659	-2457.0736
-0.084931507	0.0000
-0.252054795	-1894.0723
-0.257534247	-4008.2273
-0.482191782	-1004.2275
-0.019178082	-336.1824
-0.739726029	-4461.2622
-0.391780823	-805.2055
-0.005479452	-2715.7158
-0.167123288	-1216.5265
-0.410958905	-1813.0169
-0.082191781	0.0000
-0.915068495	-2758.6844
-0.167123288	-462.9903
-0.504109590	-1274.4028
-0.249315069	0.0000
⋮	⋮
-0.24657534	0.0000
-0.67123288	-2818.3636
-0.10684932	-610.7502
-0.06849315	-181.1018
-0.08493151	0.0000
-0.49589041	0.0000
-0.66849315	-1686.1638
-0.16164384	0.0000
-0.50410959	-2695.5949
-0.48219178	-3518.0072
-0.05205480	0.0000
-0.10958904	-3703.3999
-0.32876712	0.0000

UnidadesExpuestas	PrimaNetaPropiaSinCoaseguro
<dbl>	<dbl>
-0.41643836	-460.8016
-0.88767123	-4033.5549
-0.08493151	-2638.8796
-0.91506849	-4825.5302
-0.40273973	-126.5582
-0.16164384	0.0000
-0.16164384	0.0000
-0.53424658	-1631.6256
-0.25205479	-13333.9975
-0.16164384	0.0000
-0.15342466	-1069.8869
-0.74794521	-2412.5051
-0.64109589	-2071.0505
-0.09315068	-165.6685
-0.99178082	-1825.3856
-0.08493151	-1649.8458
-0.16164384	-411.0078

Limpiando los datos

In [147...

```
datos$signo = sign(datos$UnidadesExpuestas)
datos$UnidadesExpuestas = abs(datos$UnidadesExpuestas)
```

Las siguientes expresiones deberían ser ciertas:

- $UnidadesExpuestas = 0 \implies NumSiniestros = 0$ .
- $NumSiniestros = 0 \implies MontoOcurrido = 0$ .

Por lo que, de no cumplirse, se debe corregir.

In [148...

```
col = which(colnames(datos) %in% c("MontoOcurrido", "NumSiniestros", "UnidadesExpuestas"))
ind = which((datos$UnidadesExpuestas == 0) & (datos$NumSiniestros!=0))
datos[ind,col]
```

A tibble: 34 × 3

UnidadesExpuestas	MontoOcurrido	NumSiniestros
<dbl>	<dbl>	<dbl>
0	0.0000	1
0	0.0000	1
0	0.0000	1
0	5043.9358	2
0	20191.1836	1
0	44900.4715	1
0	211662.2741	1
0	1498.5651	1
0	714.2900	1
0	951.1667	1

UnidadesExpuestas	MontoOcurrido	NumSiniestros
<dbl>	<dbl>	<dbl>
0	667.1579	1
0	34698.7704	1
0	11580.8333	1
0	1541.8831	1
0	32198.2640	1
0	4343.9764	1
0	5440.3510	1
0	13319.3599	1
0	36357.8377	1
0	2962.0682	1
0	2921.6560	1
0	688.0954	1
0	0.0000	1
0	5383.2000	1
0	88954.8460	1
0	0.0000	1
0	120270.2400	1
0	0.0000	1
0	10712.6140	1
0	1142.3504	1
0	13596.7165	1
0	1508.0367	2
0	0.0000	1
0	8658.9826	1

Como son pocas observaciones que no cumplen con la regla ( $UnidadesExpuestas = 0 \implies NumSiniestros = 0$ ), las voy a quitar.

In [149...

```
datos = datos[-ind,]
```

La segunda regla ( $NumSiniestros = 0 \implies MontoOcurrido = 0$ ), también se rompe en pocas ocasiones, por lo que también se borran las observaciones.

In [150...

```
ind = which((datos$MontoOcurrido != 0) & (datos$NumSiniestros==0))
print(paste0("Número de observaciones irregulares: ",dim(datos[ind,col])[1]))
datos[ind,col]
```

[1] "Número de observaciones irregulares: 253"  
 A tibble: 253 × 3

UnidadesExpuestas	MontoOcurrido	NumSiniestros
<dbl>	<dbl>	<dbl>
0.08493151	4599.882	0
0.49589041	9706.784	0
0.66849315	1528.879	0
0.00000000	3218.671	0
0.66575343	20839.481	0



UnidadesExpuestas	MontoOcurrido	NumSiniestros
<dbl>	<dbl>	<dbl>
0.00000000	1005.120	0
0.00000000	2781.929	0
0.16438356	3908.783	0
0.33972603	89913.716	0
0.91506849	13990.996	0
0.66575343	139479.786	0
0.66575343	6286.348	0
0.58082192	7892.063	0
0.58082192	3424.601	0
0.16164384	0.004	0
0.16164384	15856.470	0
0.75068493	6242.400	0
0.08493151	61674.730	0
0.00000000	5451.937	0
0.00000000	3611.099	0
0.77534247	27027.791	0
0.00000000	9720.399	0
0.00000000	4758.256	0
0.00000000	24117.381	0
0.41917808	3319.640	0
0.00000000	3243.378	0
0.00000000	5349.000	0
0.08493151	13834.320	0
0.00000000	103239.257	0
0.41369863	8421.697	0
⋮	⋮	⋮
0.00000000	5.001397e+03	0
0.00000000	1.010000e-04	0
0.00000000	4.451036e+04	0
0.49589041	4.190900e+03	0
0.23287671	1.366925e+03	0
0.08493151	1.449141e+03	0
0.16164384	2.500000e+03	0
0.00000000	1.607670e+03	0
0.00000000	1.040000e-04	0
0.00000000	1.275497e+04	0
0.00000000	1.214044e+03	0
0.58082192	1.981899e+03	0
0.08493151	3.358380e+04	0
0.00000000	2.220314e+04	0
0.49589041	8.277612e+03	0
0.74794521	4.915093e+04	0
0.00000000	8.916934e+02	0

UnidadesExpuestas	MontoOcurrido	NumSiniestros
<dbl>	<dbl>	<dbl>
0.00000000	1.010000e-04	0
0.00000000	3.904770e+03	0
0.58630137	2.774659e+03	0
0.16164384	5.811060e+03	0
0.08493151	2.745128e+04	0
0.00000000	2.684871e+03	0
0.00000000	2.167627e+04	0
0.58082192	3.710934e+05	0
0.91780822	9.567518e+04	0
0.00000000	7.990272e+04	0
0.00000000	3.819400e+03	0
0.00000000	1.040000e-04	0
0.33150685	1.032098e+05	0

In [151...

```
datos = datos[-ind,]
```

In [154...

```
dim(datos)
length(apply(datos[,col],1,function(x){if(x[3] == 0){0}else{x[3]/x[1]}}))
```

49713 · 17

49713

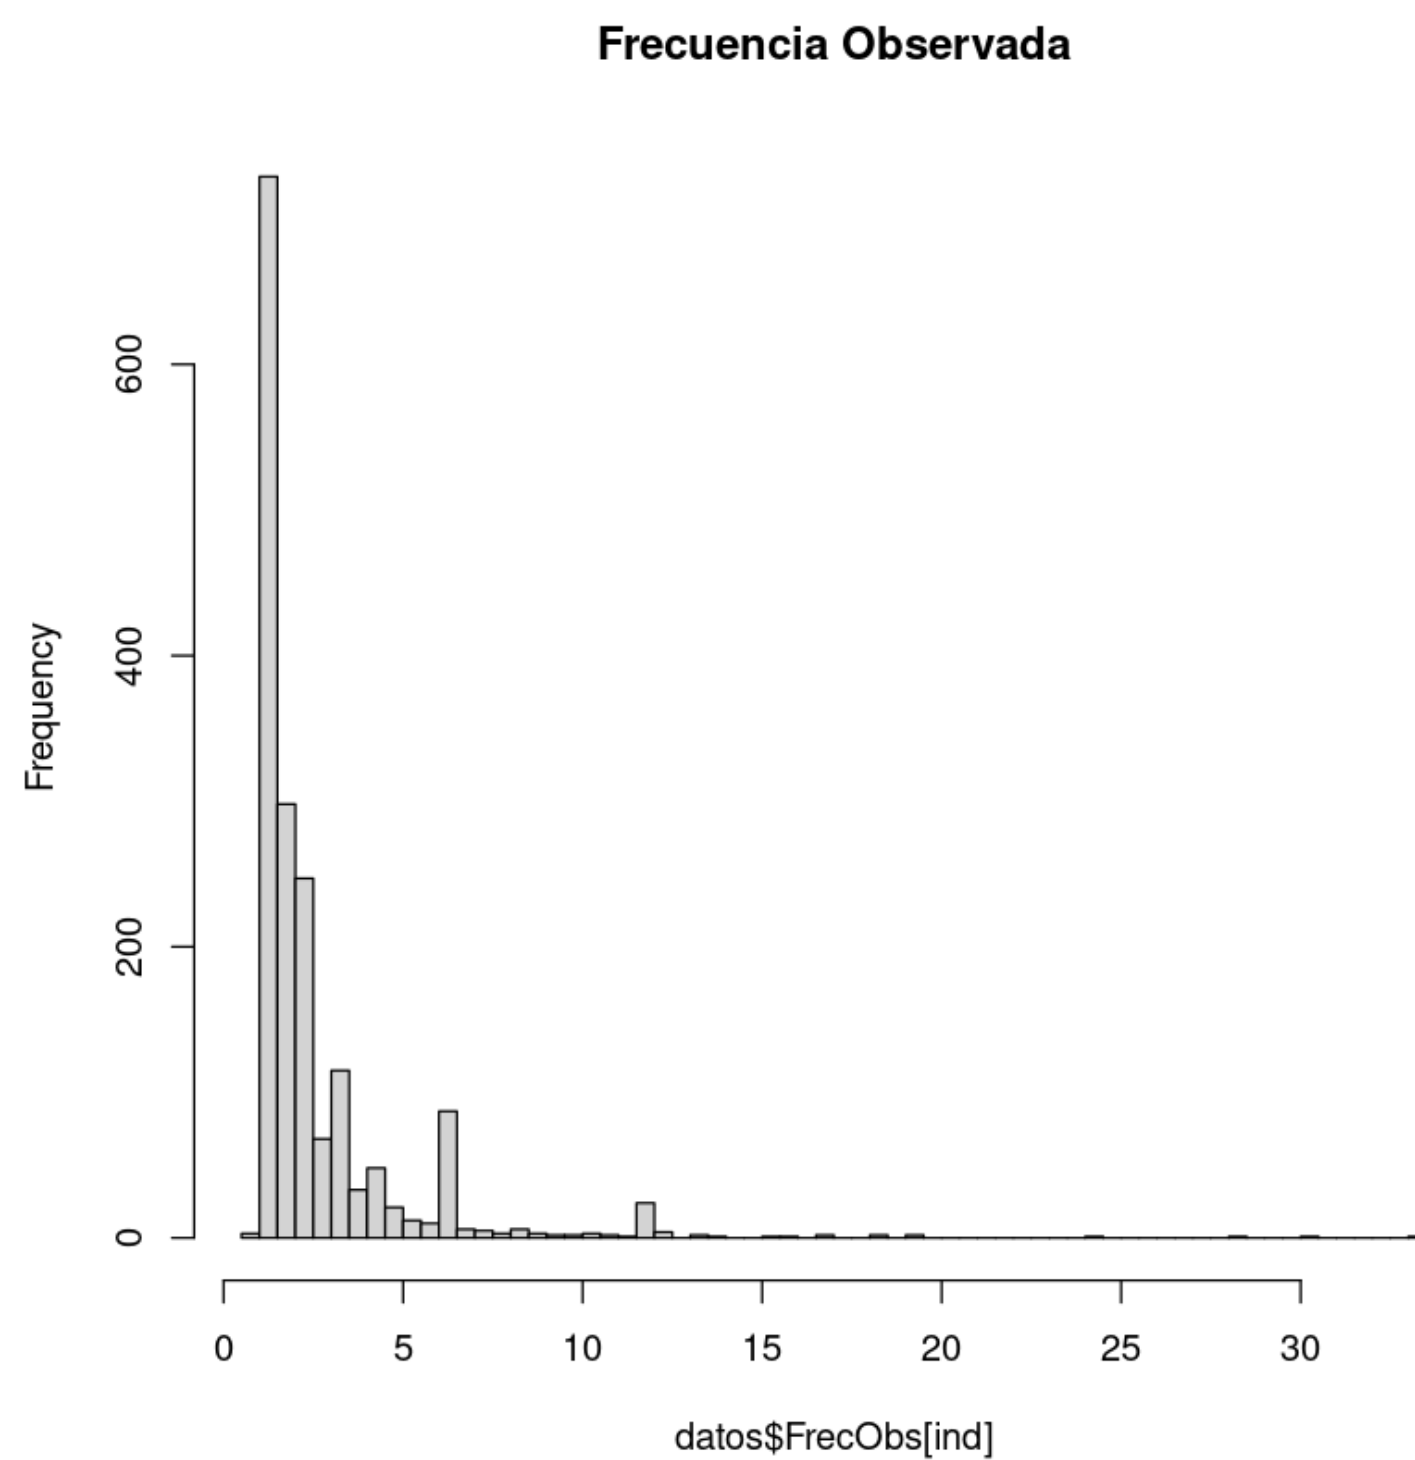
Cálculo de las variables: Frecuencia y Severidad.

In [163...

```
#Cálculo de la frecuencia observada
datos$FrecObs = apply(datos[,col],1,function(x){if(x[3] == 0){0}else{x[3]/x[1]}})
ind = which(datos$FrecObs>0)
hist(datos$FrecObs[ind], main="Frecuencia Observada", breaks = 50)
```

1747



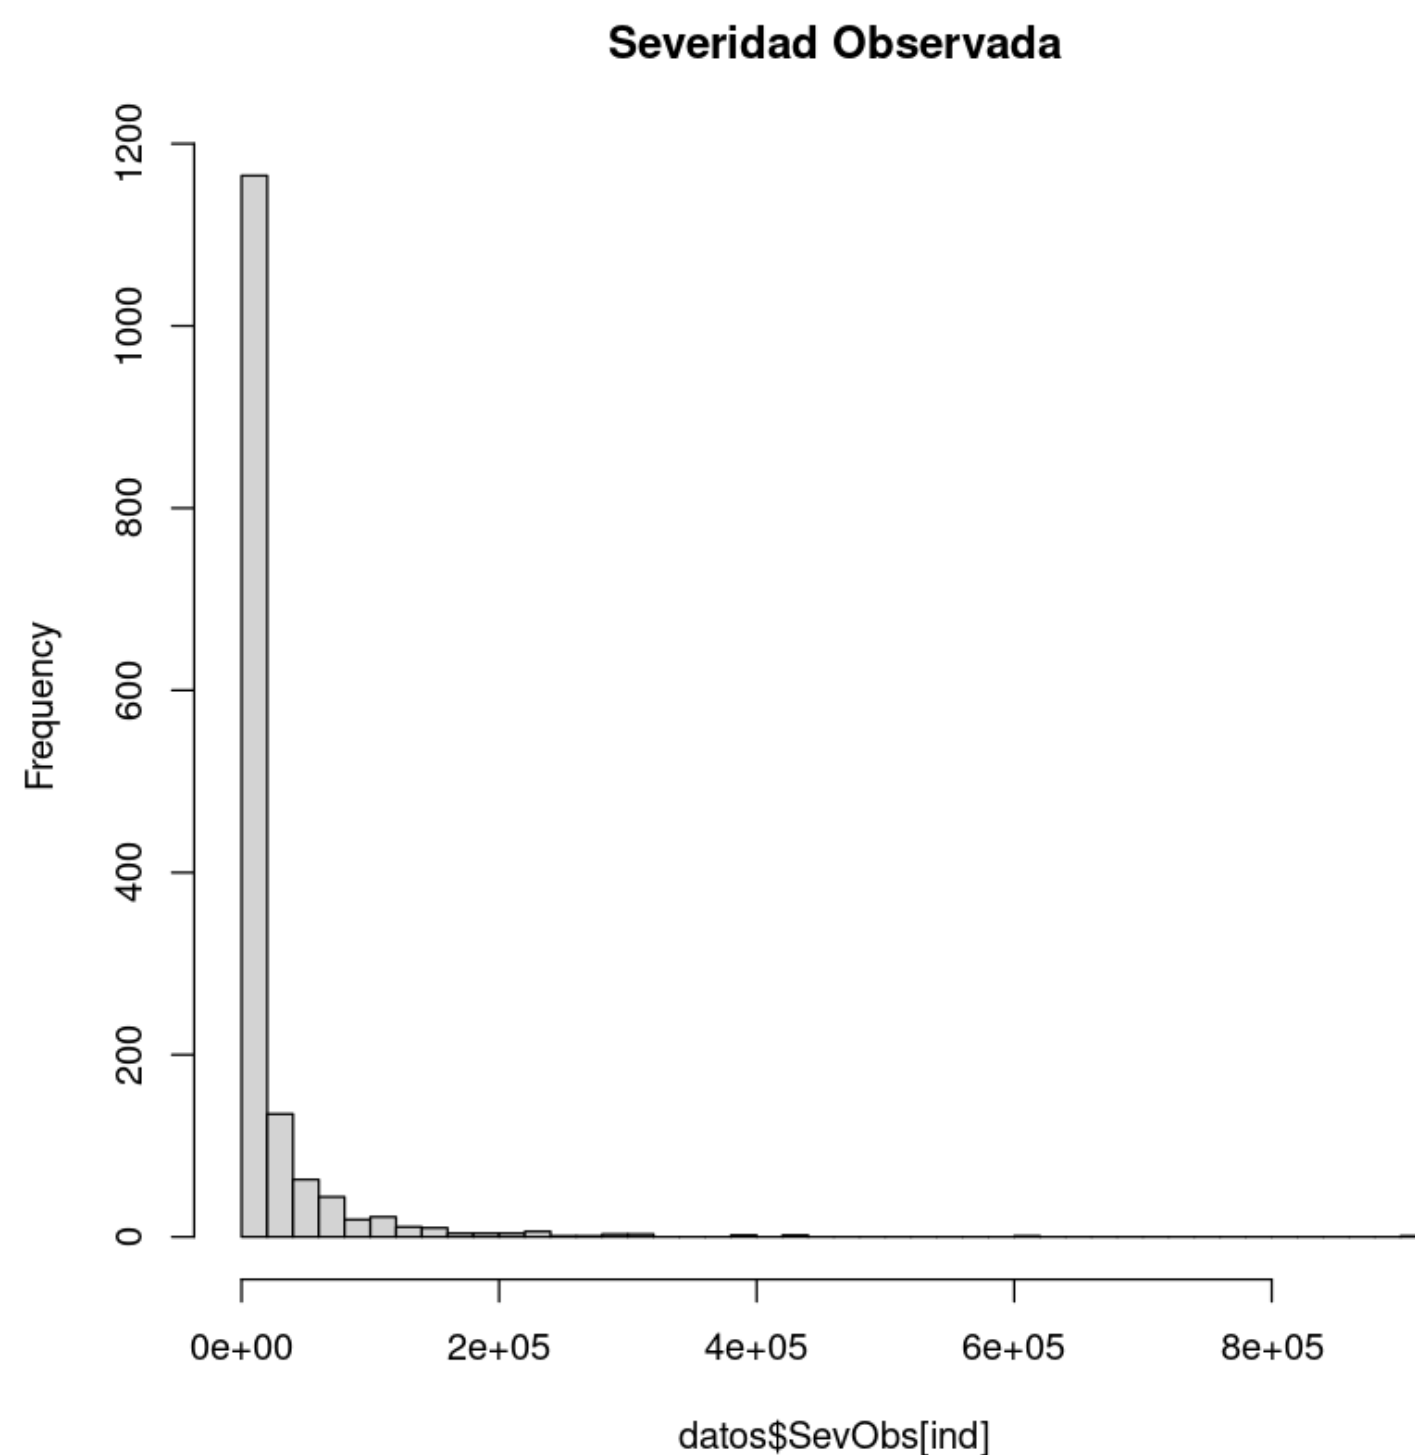


Sólo 1747 observaciones tienen una frecuencia mayor a cero.

```
In [164... length(ind)
```

1747

```
In [165... #Cálculo de la severidad observada  
datos$SevObs = apply(datos[,col],1,function(x){if(x[2] == 0){0}else{x[2]/x[3]}})  
ind = which(datos$SevObs>0)  
hist(datos$SevObs[ind], main="Severidad Observada", breaks = 50)
```



Sólo 1501 observaciones tienen una severidad mayor a cero.

```
In [166... length(ind)
```

In [172...

```
datos$Anio = as.factor(datos$Anio)
```

Estadística descriptiva del resto de variables.

In [567...

```
#Estadística para la Frecuencia Observada

ind = which(datos$FrecObs>0)

img1 = ggplot(datos[ind,], aes(x = DescTipoVehiculo, y = log(FrecObs), color = DescTipoVehiculo)) +
  labs(title = "Log-Frecuencia por DescTipoVehiculo", y= "Log-Frecuencia Observada", x = "DescTipoVehiculo")

img2 = ggplot(datos[ind,], aes(x = TipoPersona, y = log(FrecObs), color = TipoPersona)) +
  labs(title = "Log-Frecuencia por TipoPersona", y= "Log-Frecuencia Observada", x = "TipoPersona")

datos$Edadx = as.factor(as.integer(datos$Edad /10)*10)
img3 = ggplot(datos[ind,], aes(x = Edadx, y = log(FrecObs), color = Edadx)) + geom_boxplot()
labs(title = "Log-Frecuencia observada por Edad", y= "Log-Frecuencia Observada", x = "Edad")

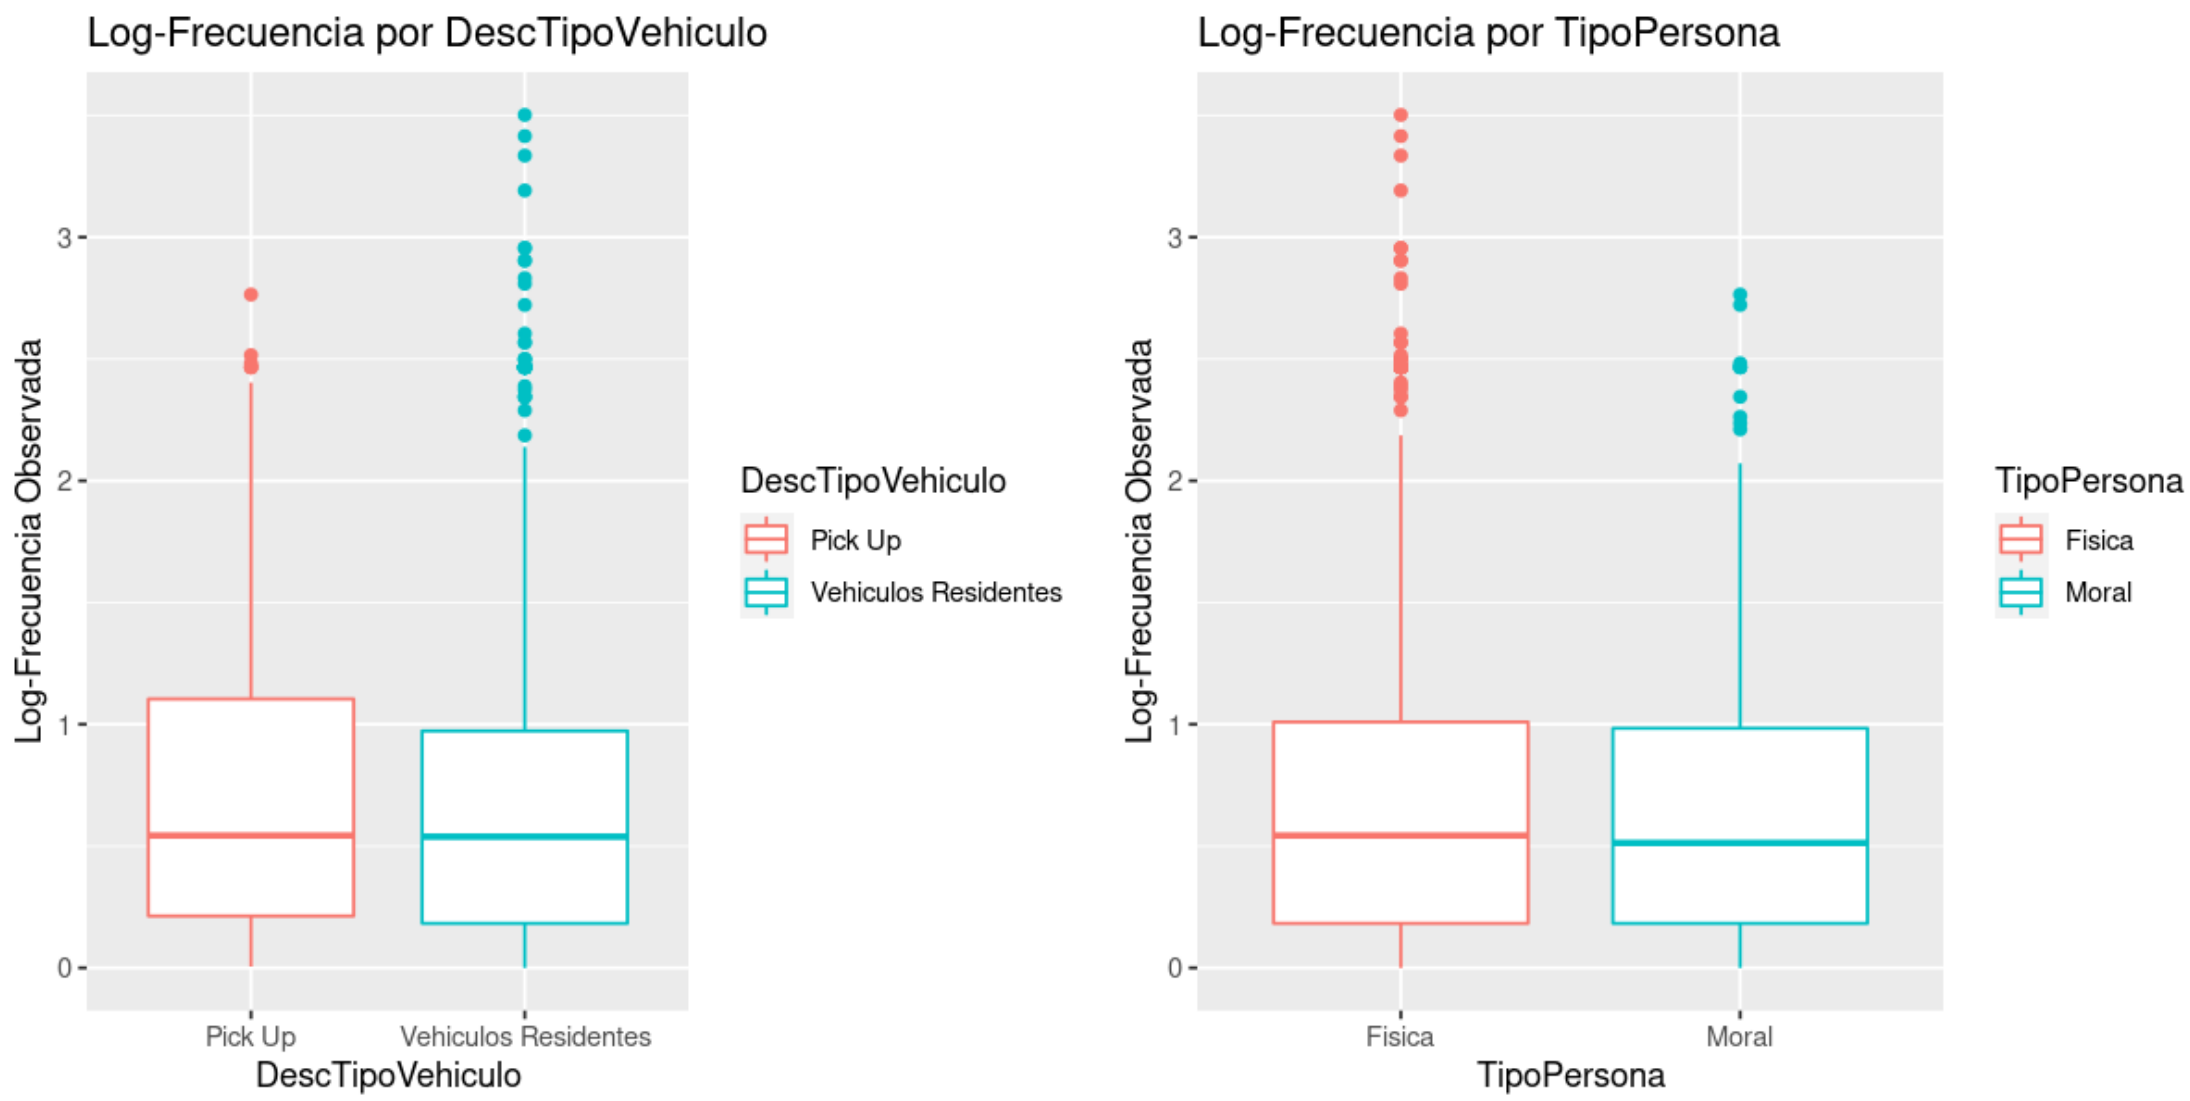
img4 = ggplot(datos[ind,], aes(x = Sexo, y = log(FrecObs), color = Sexo)) + geom_boxplot()
labs(title = "Log-Frecuencia observada por Sexo", y= "Log-Frecuencia Observada", x = "Sexo")

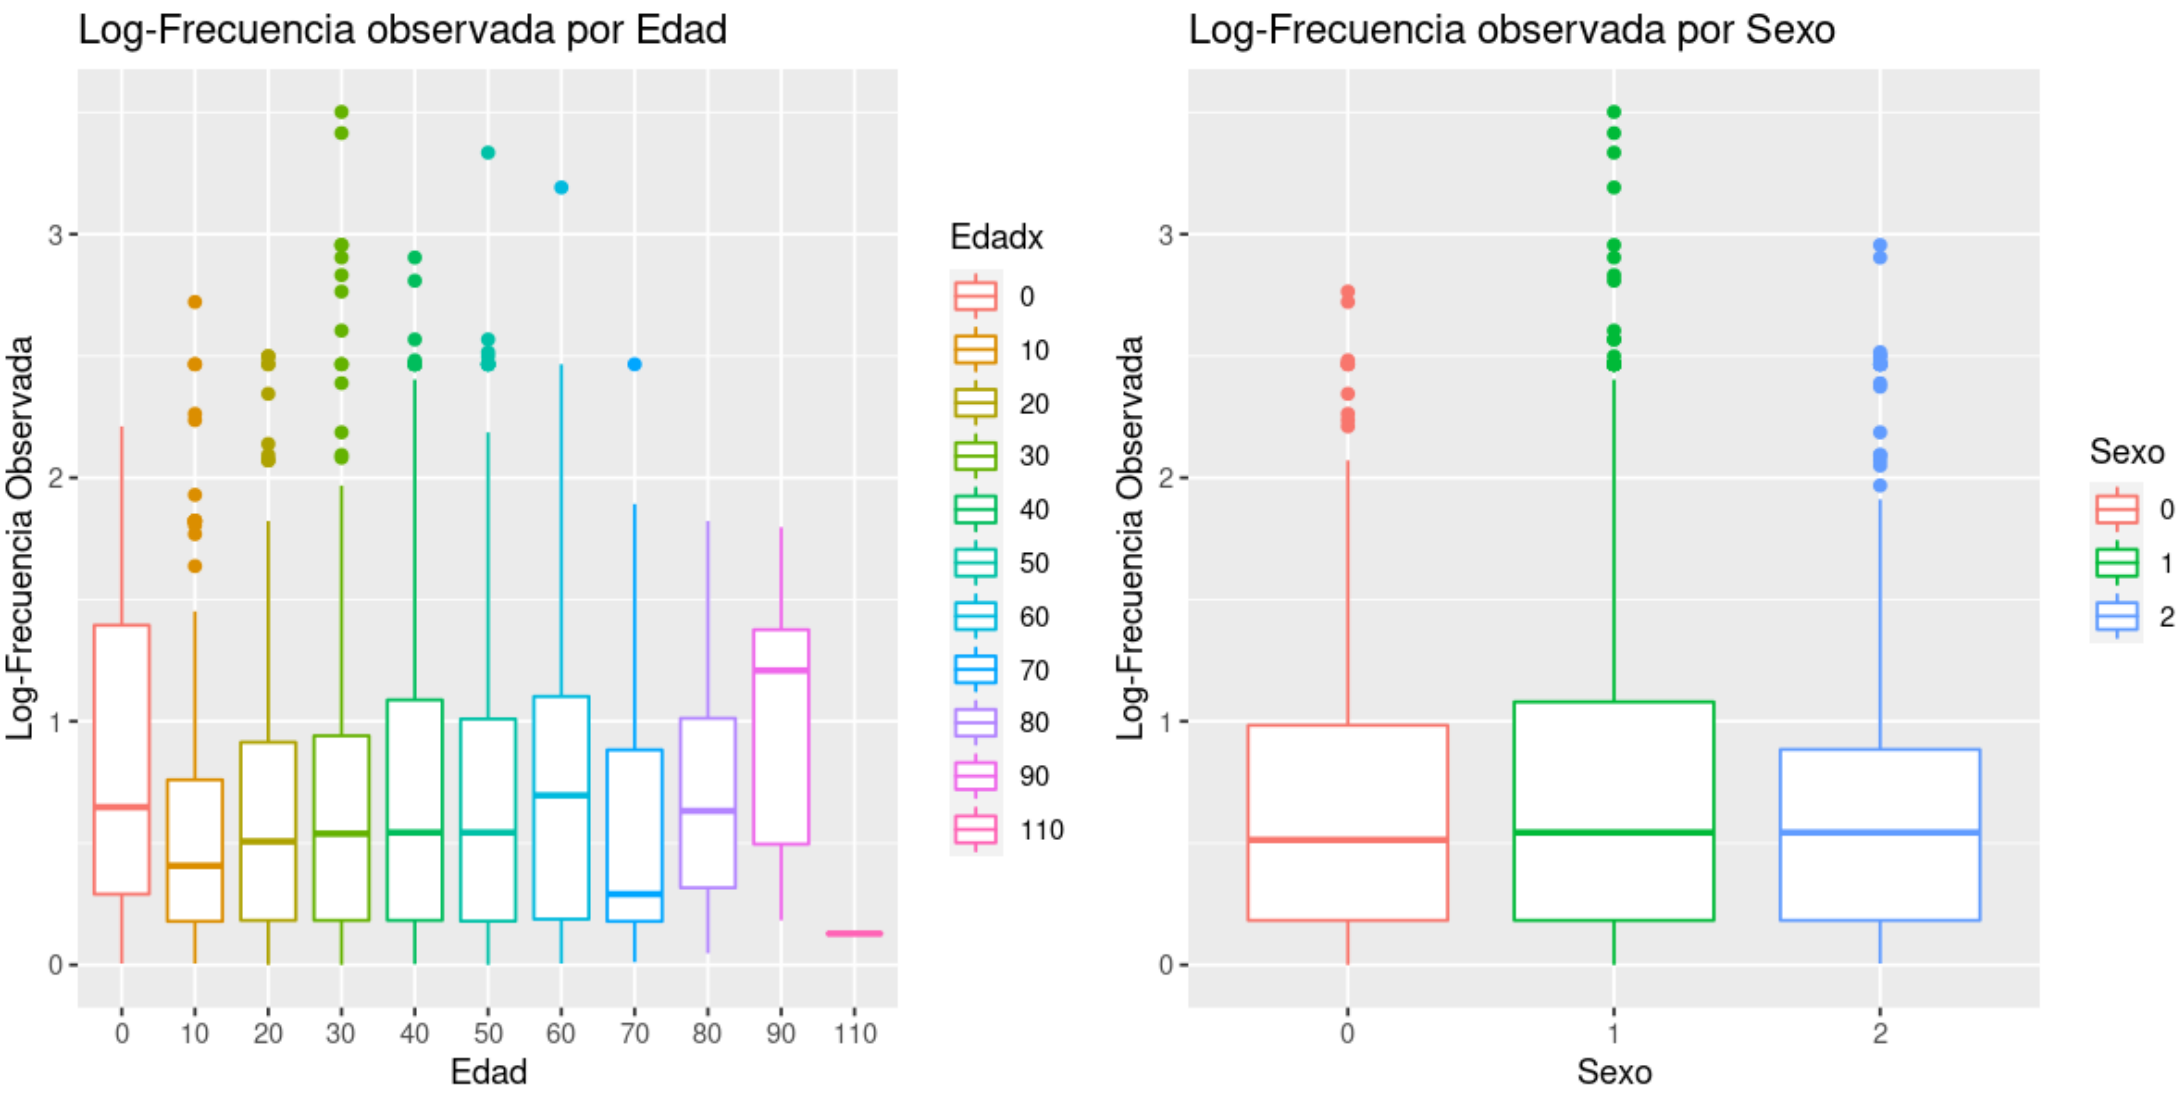
datos$ModeloVehiculo = as.factor(datos$ModeloVehiculo)
img5 = ggplot(datos[ind,], aes(x = ModeloVehiculo, y = log(FrecObs), color = ModeloVehiculo)) +
  labs(title = "Log-Frecuencia observada por ModeloVehiculo", y= "Log-Frecuencia Observada")
datos$ModeloVehiculo = as.integer(datos$ModeloVehiculo)

img6 = ggplot(datos[ind,], aes(x = DescUsoVehiculo, y = log(FrecObs), color = DescUsoVehiculo)) +
  labs(title = "Log-Frecuencia observada por DescUsoVehiculo", y= "Log-Frecuencia DescUsoVehiculo")


img7 = ggplot(datos[ind,], aes(x = DescMarcaVehiculo, y = log(FrecObs), color = DescMarcaVehiculo)) +
  labs(title = "Log-Frecuencia observada por DescMarcaVehiculo", y= "Log-Frecuencia DescMarcaVehiculo")

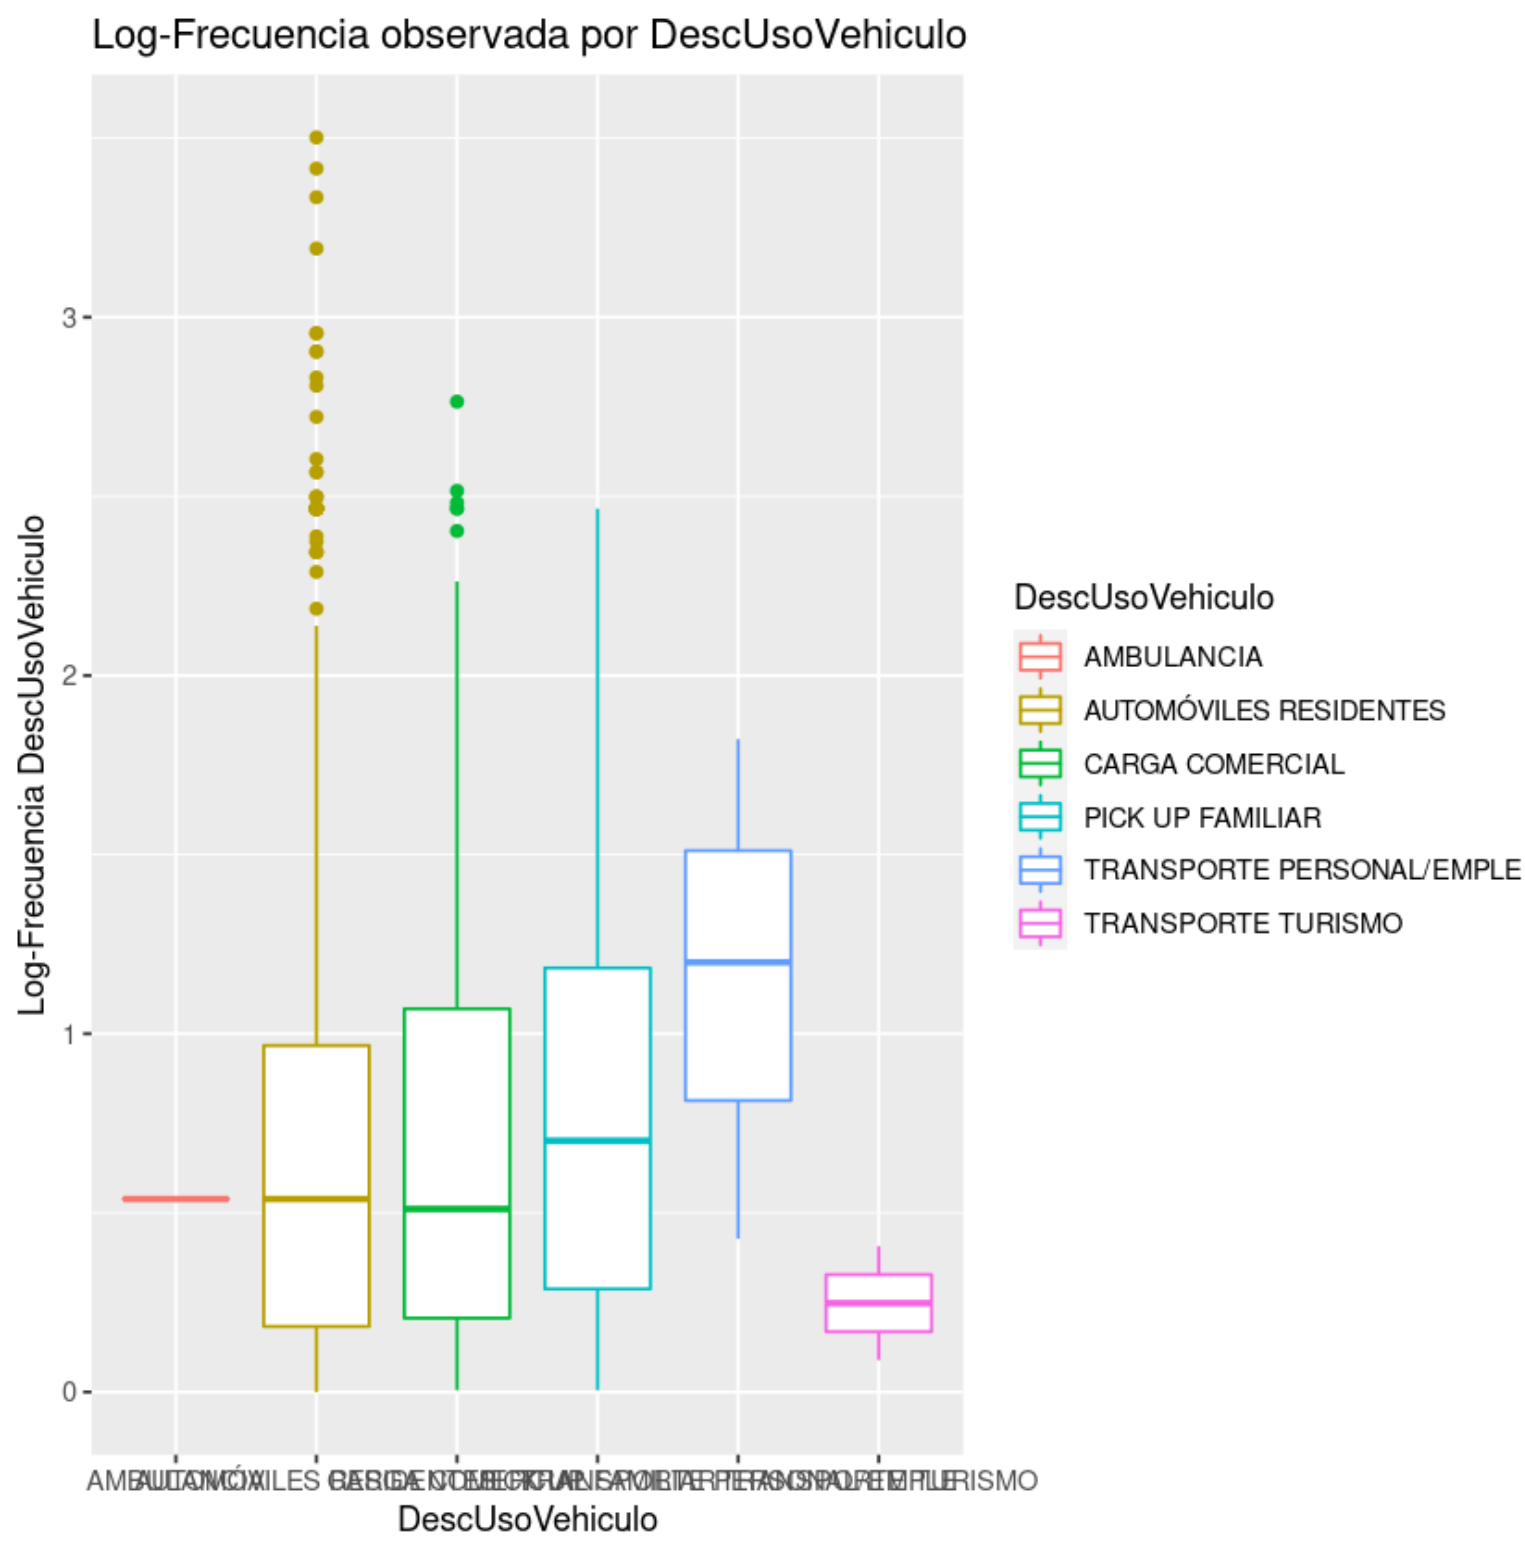
options( repr.plot.height = 5)
ggarrange(img1,img2, ncol = 2)
ggarrange(img3,img4, ncol = 2)
```






```
In [245... options(repr.plot.width = 7, repr.plot.height = 7)
img5
img6
```





In [568...

img7



Observación.

De los diagramas anteriores, sugieren que las mejores variables que más reflejan la variabilidad de la frecuencia pueden ser:

- DescUsoVehiculo: En especial el Transporte para Turismo y de Personal.
- Edad: Sobre todo, en edades mayores a los 50 años.

In [562...

*#Estadística para la Severidad Observada*

```
ind = which(datos$SevObs>0)
```

```
img1 = ggplot(datos[ind,], aes(x = DescTipoVehiculo, y = log(SevObs), color = DescTipoVehiculo)) +  
  labs(title = "Log-Severidad por DescTipoVehiculo", y= "Log-Severidad Observada", x = "DescTipoVehiculo")
```

```
img2 = ggplot(datos[ind,], aes(x = TipoPersona, y = log(SevObs), color = TipoPersona)) +  
  labs(title = "Log-Severidad por TipoPersona", y= "Log-Severidad Observada", x = "TipoPersona")
```

```
datos$Edadx = as.factor(as.integer(datos$Edad /10)*10)
```

```
img3 = ggplot(datos[ind,], aes(x = Edadx, y = log(SevObs), color = Edadx)) + geom_boxplot()
```

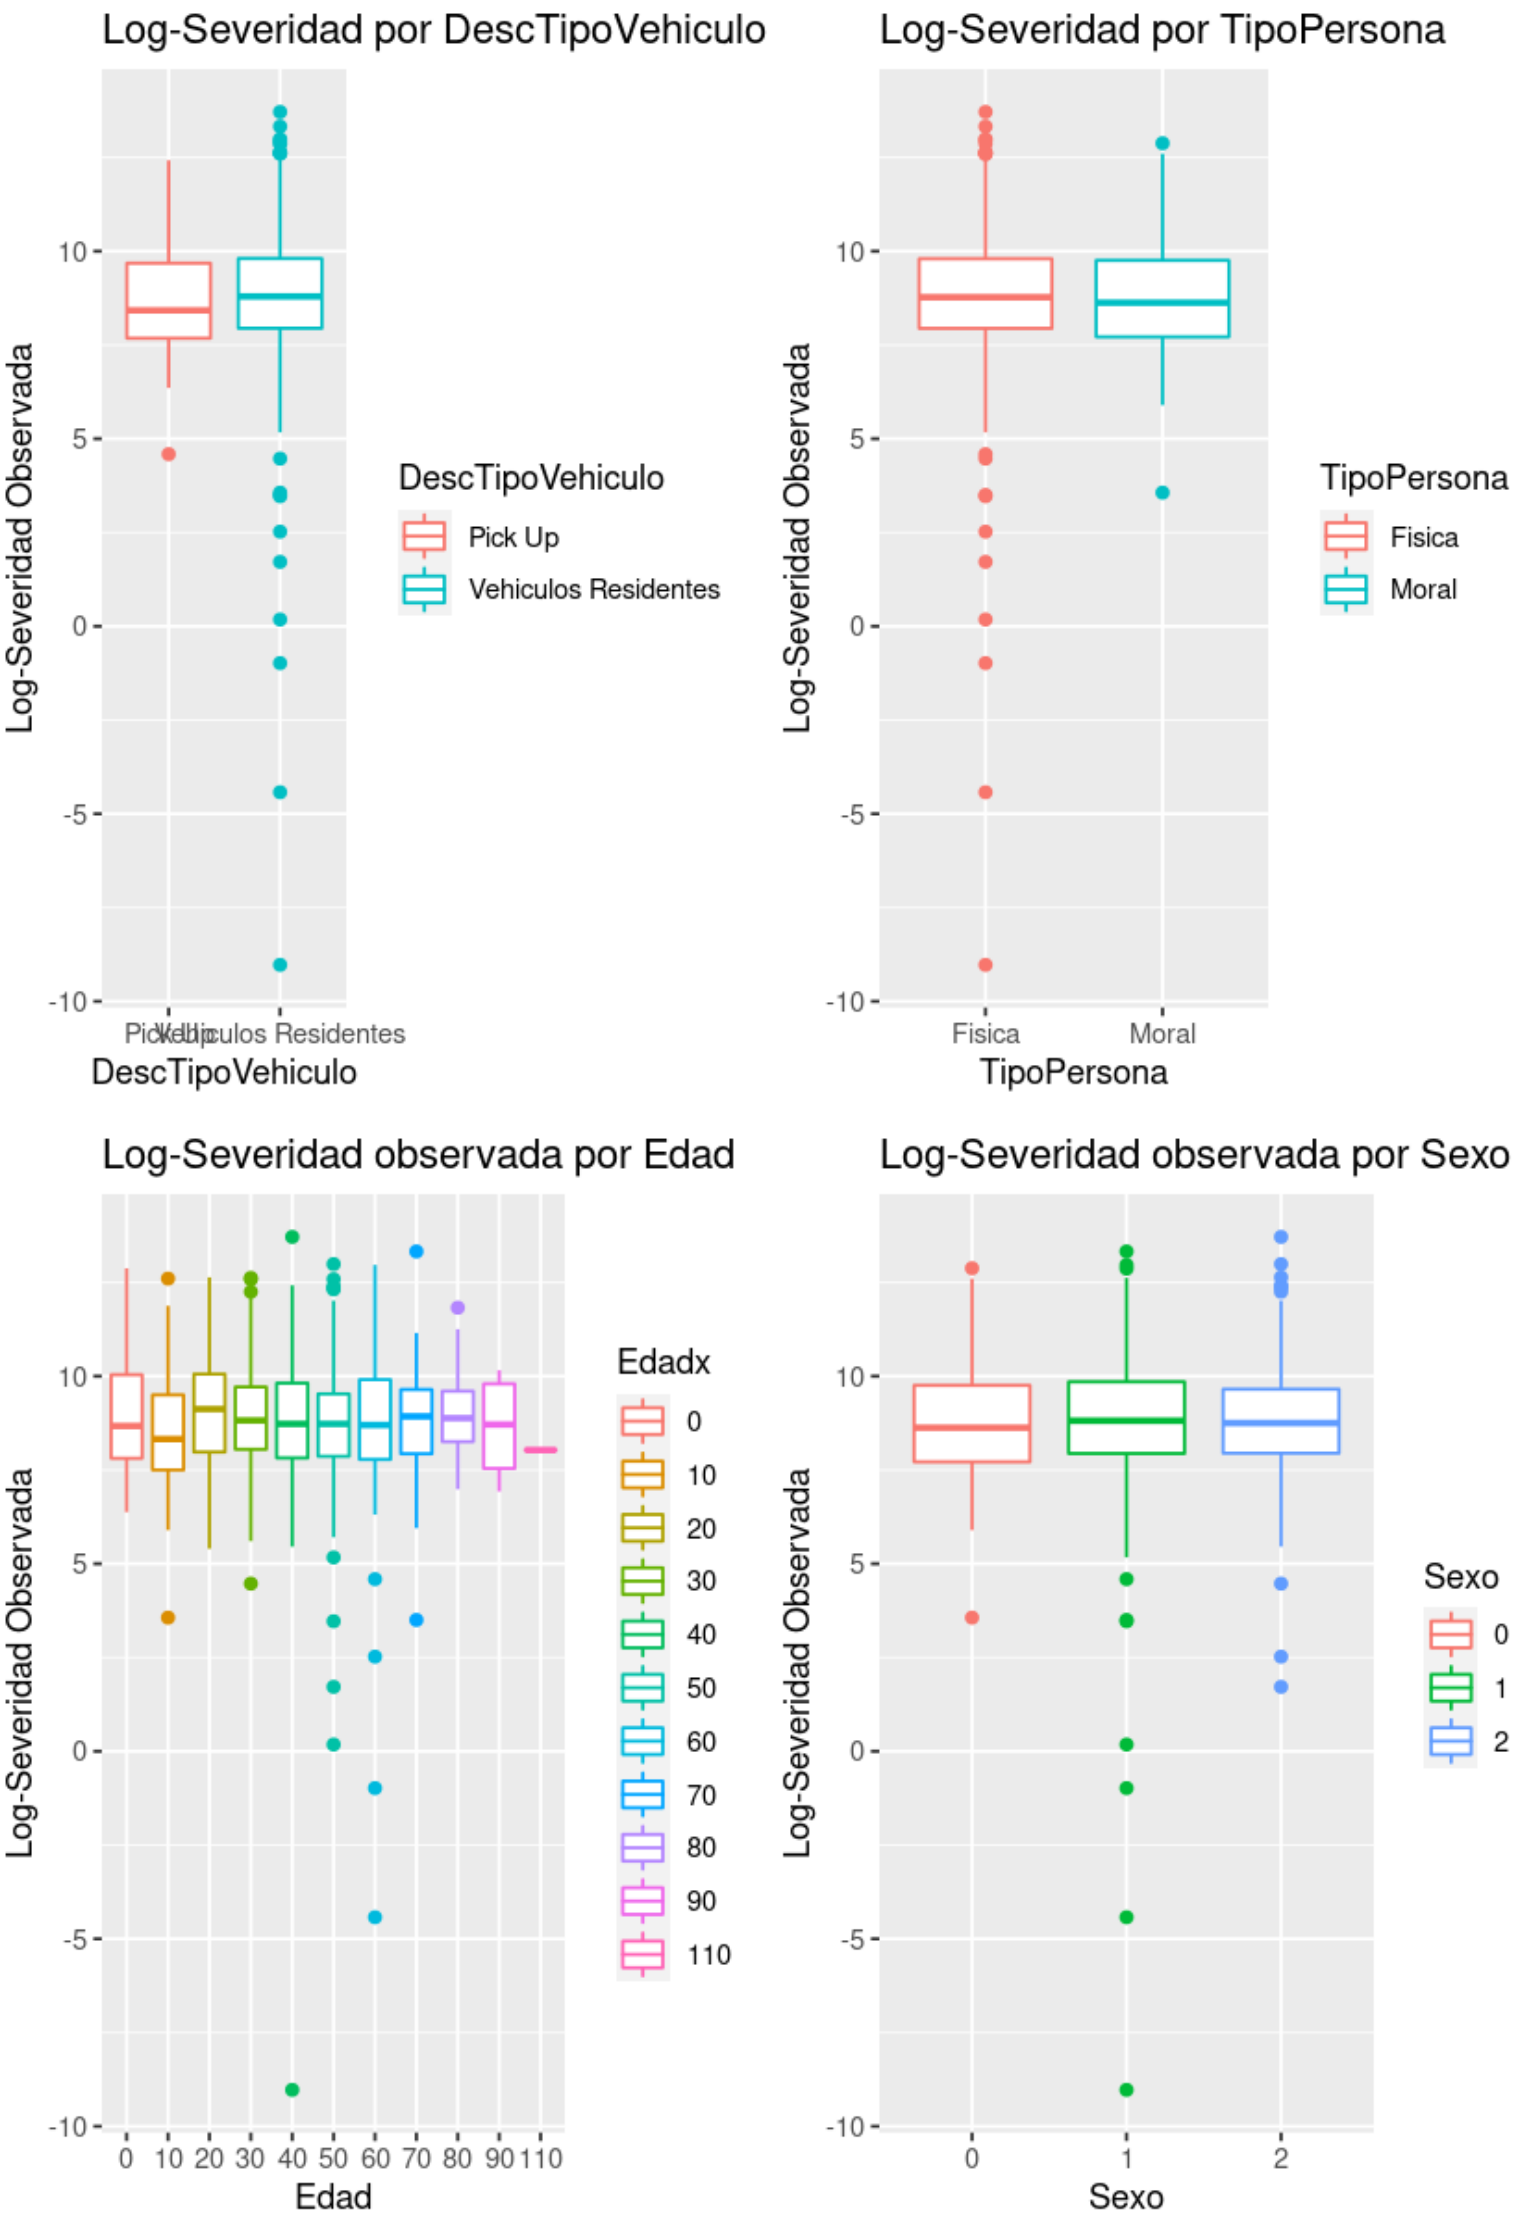
```
labs(title = "Log-Severidad observada por Edad", y= "Log-Severidad Observada", x = "Edad")

img4 = ggplot(datos[ind,], aes(x = Sexo, y = log(SevObs), color = Sexo)) + geom_boxplot()
labs(title = "Log-Severidad observada por Sexo", y= "Log-Severidad Observada", x = "Sexo")

datos$ModeloVehiculo = as.factor(datos$ModeloVehiculo)
img5 = ggplot(datos[ind,], aes(x = ModeloVehiculo, y = log(SevObs), color = ModeloVehiculo)) + geom_boxplot()
labs(title = "Log-Severidad observada por ModeloVehiculo", y= "Log-Severidad Observada", x = "ModeloVehiculo")
datos$ModeloVehiculo = as.integer(datos$ModeloVehiculo)

img7 = ggplot(datos[ind,], aes(x = DescMarcaVehiculo, y = log(SevObs), color = DescMarcaVehiculo)) + geom_boxplot()
labs(title = "Log-Severidad observada por DescMarcaVehiculo", y= "Log-Severidad DescMarcaVehiculo", x = "DescMarcaVehiculo")


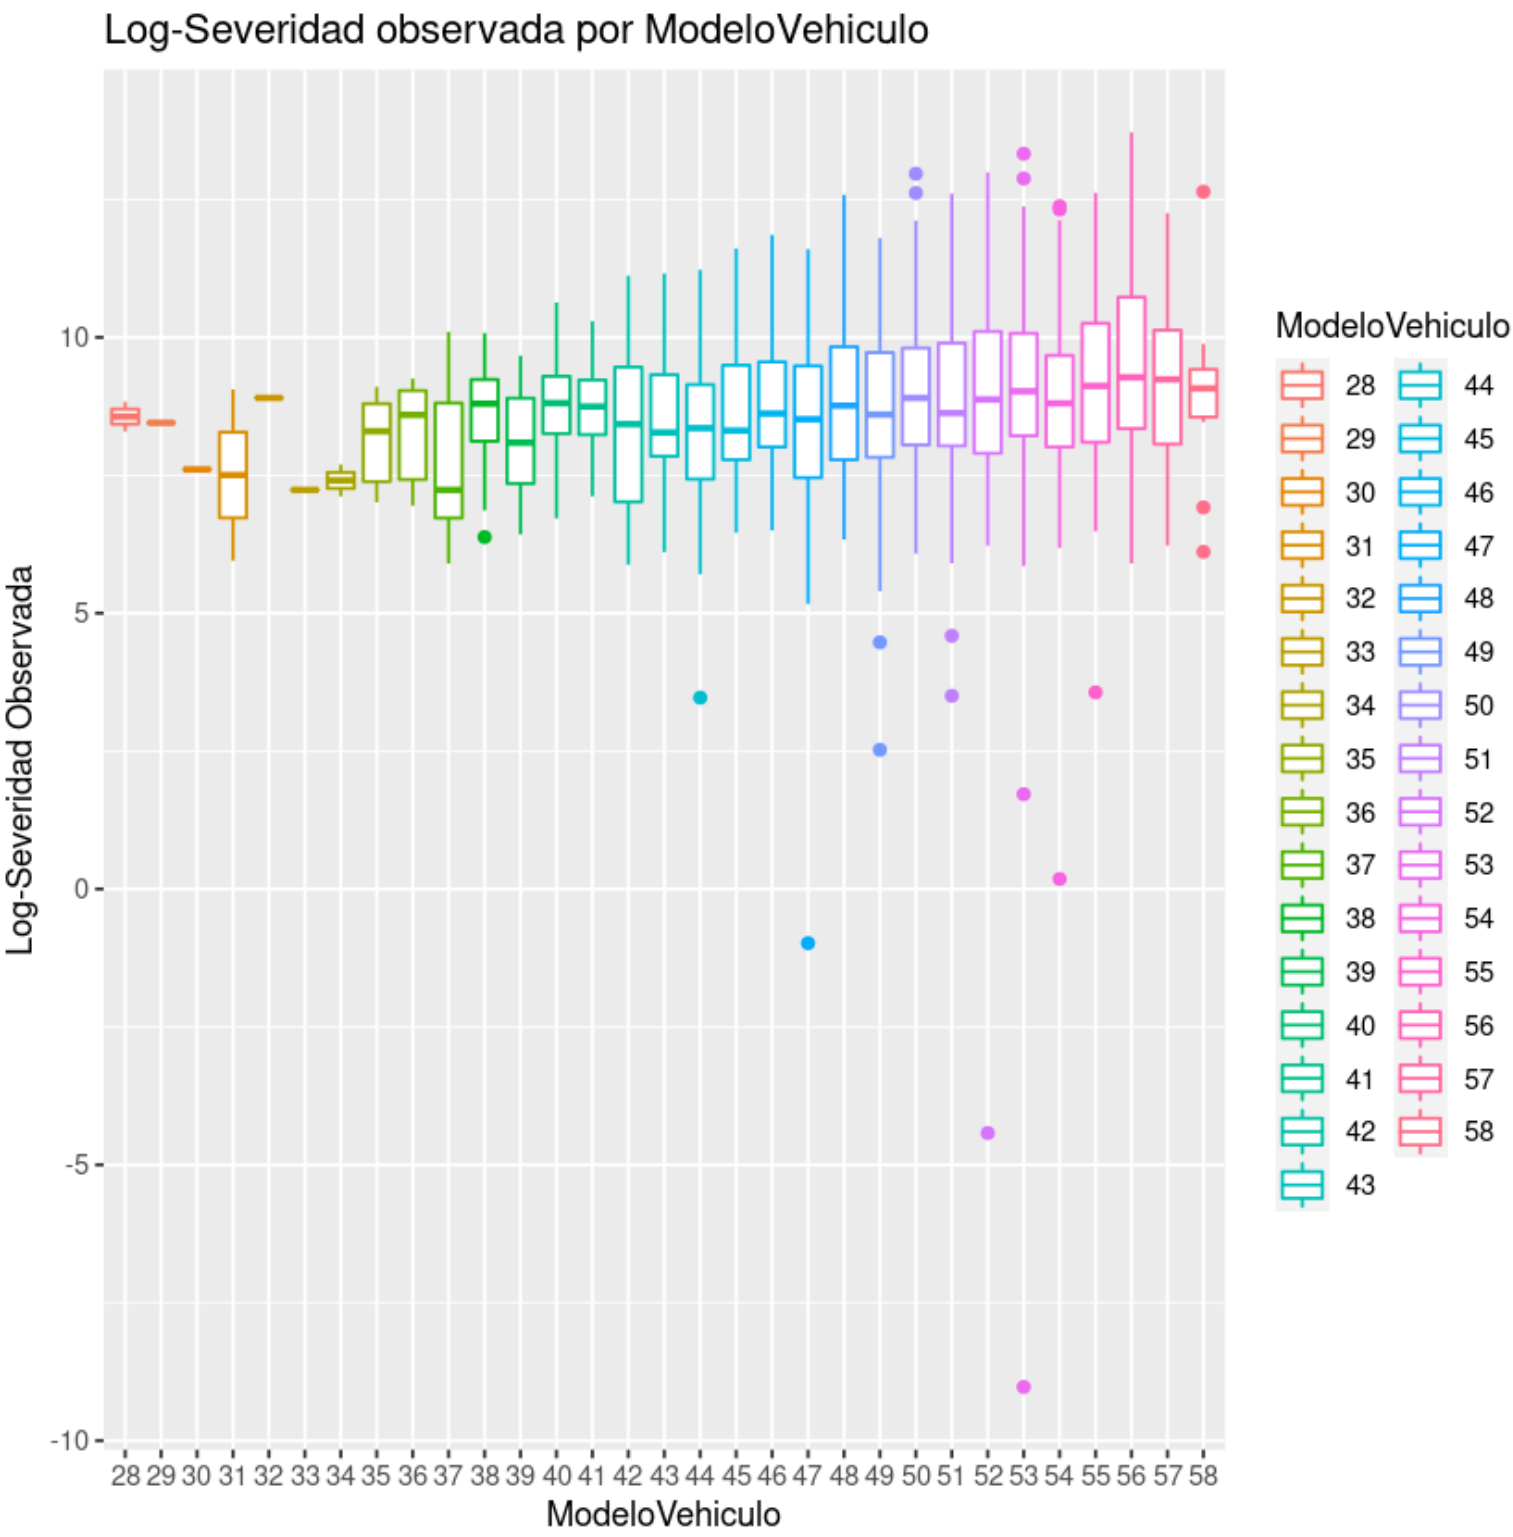
options( repr.plot.height = 5)
ggarrange(img1,img2, ncol = 2)
ggarrange(img3,img4, ncol = 2)
```



In [248...

```
options(repr.plot.width = 7, repr.plot.height = 7)
img5
img6
```






In [564...

```
options(repr.plot.width = 10, repr.plot.height = 10)
img7
```





Observación.

De los diagramas anteriores, sugieren que las mejores variables que más reflejan la variabilidad de la severidad pueden ser:

- ModeloVehiculo: Muestra una tendencia creciente respecto del modelo.
- DescUsoVehiculo: Muestra una ligera diferencia entre los tipos de uso del vehiculo, pero parece haber diferencias marcadas entre una ambulancia y el transporte de turismo.

Quitando variables faltantes.

In [256...

```
apply(datos,2,function(x){any(is.na(x))})
```

Anio: FALSE ID: FALSE NombreOficina: FALSE UnidadesExpuestas: FALSE NombreSubdireccion: TRUE  
DescTipoVehiculo: FALSE TipoPersona: TRUE Edad: TRUE Sexo: TRUE DescMarcaVehiculo: FALSE  
DescCarroceriaVehiculo: FALSE ModeloVehiculo: FALSE DescUsoVehiculo: FALSE  
PrimaNetaPropiaSinCoaseguro: FALSE MontoOcurrido: FALSE NumSiniestros: FALSE signo: FALSE  
FrecObs: FALSE SevObs: FALSE Edadx: TRUE

In [262...

```
#quitando NA de TipoPersona  
nas = which(is.na(datos$TipoPersona))  
print(paste0("Quitando ",length(nas)," observaciones."))  
datos = datos[-nas,]
```

[1] "Quitando 84 observaciones."

In [264...

```
#quitando NA de Edad
```

```
nas = which(is.na(datos$Edad))
print(paste0("Quitando ",length(nas)," observaciones."))
datos = datos[-nas,]
```

[1] "Quitando 20 observaciones."

In [267...

```
#quitando NA de NombreSubdireccion
nas = which(is.na(datos$NombreSubdireccion))
print(paste0("Quitando ",length(nas)," observaciones."))
datos = datos[-nas,]
```

[1] "Quitando 1 observaciones."

Se convertiran los factores dentro de los datos dummy, ya que el paquete Rfast2 requiere esa representación.

In [269...

```
apply(datos,2,class)
```

Anio: 'character' ID: 'character' NombreOficina: 'character' UnidadesExpuestas: 'character'  
NombreSubdireccion: 'character' DescTipoVehiculo: 'character' TipoPersona: 'character' Edad: 'character'  
Sexo: 'character' DescMarcaVehiculo: 'character' DescCarroceriaVehiculo: 'character' ModeloVehiculo:  
'character' DescUsoVehiculo: 'character' PrimaNetaPropiaSinCoaseguro: 'character' MontoOcurrido:  
'character' NumSiniestros: 'character' signo: 'character' FrecObs: 'character' SevObs: 'character' Edadx:  
'character'

In [310...

```
datos$Anio = as.integer(datos$Anio)
datos$Edad = as.integer(datos$Edad)
datos$ModeloVehiculo = as.integer(datos$ModeloVehiculo)
```

In [357...

```
DescMarcaVehiculo = model.matrix( ~ DescMarcaVehiculo - 1, datos)
dim(DescMarcaVehiculo)
head(DescMarcaVehiculo)
```

49608 · 57

	DescMarcaVehiculoACURA	DescMarcaVehiculoALFA ROMEO	DescMarcaVehiculoAUDI	DescMarcaVehiculoBAIC	DescMar
1	0	0	0	0	
2	0	0	0	0	
3	0	0	0	0	
4	0	0	0	0	
5	0	0	0	0	
6	0	0	0	0	

In [358...

```
colnames(DescMarcaVehiculo)
```

'DescMarcaVehiculoACURA' · 'DescMarcaVehiculoALFA ROMEO' · 'DescMarcaVehiculoAUDI' ·  
'DescMarcaVehiculoBAIC' · 'DescMarcaVehiculoBMW' · 'DescMarcaVehiculoBUICK' ·  
'DescMarcaVehiculoCADILLAC' · 'DescMarcaVehiculoCHANGAN' · 'DescMarcaVehiculoCHEVROLET' ·  
'DescMarcaVehiculoCHRYSLER' · 'DescMarcaVehiculoCLASICO' · 'DescMarcaVehiculoCUPRA' ·  
'DescMarcaVehiculoDFSK' · 'DescMarcaVehiculoDODGE' · 'DescMarcaVehiculoFAW' ·  
'DescMarcaVehiculoFIAT' · 'DescMarcaVehiculoFORD' · 'DescMarcaVehiculoGIANT' ·  
'DescMarcaVehiculoGMC' · 'DescMarcaVehiculoHINO' · 'DescMarcaVehiculoHONDA' ·  
'DescMarcaVehiculoHUMMER' · 'DescMarcaVehiculoHYUNDAI' · 'DescMarcaVehiculoINFINITI' ·  
'DescMarcaVehiculoISUZU' · 'DescMarcaVehiculoJAC' · 'DescMarcaVehiculoJAGUAR' ·  
'DescMarcaVehiculoJEEP' · 'DescMarcaVehiculoKIA' · 'DescMarcaVehiculoLAND ROVER' ·

'DescMarcaVehiculoLINCOLN' · 'DescMarcaVehiculoMASERATI' · 'DescMarcaVehiculoMAZDA' ·  
'DescMarcaVehiculoMERCEDES BENZ' · 'DescMarcaVehiculoMERCURY' · 'DescMarcaVehiculoMG' ·  
'DescMarcaVehiculoMINI' · 'DescMarcaVehiculoMITSUBISHI' · 'DescMarcaVehiculoNISSAN' ·  
'DescMarcaVehiculoPEUGEOT' · 'DescMarcaVehiculoPIAGGIO' · 'DescMarcaVehiculoPONTIAC' ·  
'DescMarcaVehiculoPORSCHE' · 'DescMarcaVehiculoRAM' · 'DescMarcaVehiculoRENAULT' ·  
'DescMarcaVehiculoROVER' · 'DescMarcaVehiculoSAAB' · 'DescMarcaVehiculoSEAT' ·  
'DescMarcaVehiculoSMART' · 'DescMarcaVehiculoSPARTAK' · 'DescMarcaVehiculoSTRUDER' ·  
'DescMarcaVehiculoSUBARU' · 'DescMarcaVehiculoSUZUKI' · 'DescMarcaVehiculoTODAS' ·  
'DescMarcaVehiculoTOYOTA' · 'DescMarcaVehiculoVOLKSWAGEN' · 'DescMarcaVehiculoVOLVO'

In [571]...

```
datos$HONDA = DescMarcaVehiculo[,which(colnames(DescMarcaVehiculo) == 'DescMarcaVehiculoHONDA')]  
datos$TOYOTA = DescMarcaVehiculo[,which(colnames(DescMarcaVehiculo) == 'DescMarcaVehiculoTOYOTA')]
```

In [363]...

```
colnames(DescMarcaVehiculo)
```

'DescMarcaVehiculoACURA' · 'DescMarcaVehiculoALFA ROMEO' · 'DescMarcaVehiculoAUDI' ·  
'DescMarcaVehiculoBAIC' · 'DescMarcaVehiculoBMW' · 'DescMarcaVehiculoBUICK' ·  
'DescMarcaVehiculoCADILLAC' · 'DescMarcaVehiculoCHANGAN' · 'DescMarcaVehiculoCHEVROLET' ·  
'DescMarcaVehiculoCHRYSLER' · 'DescMarcaVehiculoCLASICO' · 'DescMarcaVehiculoCUPRA' ·  
'DescMarcaVehiculoDFSK' · 'DescMarcaVehiculoDODGE' · 'DescMarcaVehiculoFAW' ·  
'DescMarcaVehiculoFIAT' · 'DescMarcaVehiculoFORD' · 'DescMarcaVehiculoGIANT' ·  
'DescMarcaVehiculoGMC' · 'DescMarcaVehiculoHINO' · 'DescMarcaVehiculoHONDA' ·  
'DescMarcaVehiculoHUMMER' · 'DescMarcaVehiculoHYUNDAI' · 'DescMarcaVehiculoINFINITI' ·  
'DescMarcaVehiculoISUZU' · 'DescMarcaVehiculoJAC' · 'DescMarcaVehiculoJAGUAR' ·  
'DescMarcaVehiculoJEEP' · 'DescMarcaVehiculoKIA' · 'DescMarcaVehiculoLAND ROVER' ·  
'DescMarcaVehiculoLINCOLN' · 'DescMarcaVehiculoMASERATI' · 'DescMarcaVehiculoMAZDA' ·  
'DescMarcaVehiculoMERCEDES BENZ' · 'DescMarcaVehiculoMERCURY' · 'DescMarcaVehiculoMG' ·  
'DescMarcaVehiculoMINI' · 'DescMarcaVehiculoMITSUBISHI' · 'DescMarcaVehiculoNISSAN' ·  
'DescMarcaVehiculoPEUGEOT' · 'DescMarcaVehiculoPIAGGIO' · 'DescMarcaVehiculoPONTIAC' ·  
'DescMarcaVehiculoPORSCHE' · 'DescMarcaVehiculoRAM' · 'DescMarcaVehiculoRENAULT' ·  
'DescMarcaVehiculoROVER' · 'DescMarcaVehiculoSAAB' · 'DescMarcaVehiculoSEAT' ·  
'DescMarcaVehiculoSMART' · 'DescMarcaVehiculoSPARTAK' · 'DescMarcaVehiculoSTRUDER' ·  
'DescMarcaVehiculoSUBARU' · 'DescMarcaVehiculoSUZUKI' · 'DescMarcaVehiculoTODAS' ·  
'DescMarcaVehiculoTOYOTA' · 'DescMarcaVehiculoVOLKSWAGEN' · 'DescMarcaVehiculoVOLVO'

## Modelación

Decidi modelar ambas variables con un Tweedie, ya que es una familia de distribuciones que puede aproximar al modelo Gamma - Cero Inflado. Donde el modelo Gamma cero inflado podría apropiado por las siguientes razones:

- Si no ocurre el siniestro, las variables pueden tomar el valor 0 (que, además es la moda de los valores calculados).
- En principio ambas variables son positivas, siempre y cuando ocurra el siniestro.

El modelo Gamma - Cero Inflado combina una regresión Bernoulli, con una regresión Gamma. De esta forma, la gamma sólo se expresa si previamente la regresión Bernoulli no toma el valor cero.

Nota: Si bien, una opción modelarlos de esta manera, también se pudo haber intentado un modelo de Cuasi-verosimilitud.

## Modelo de la Frecuencia



```
In [331... colnames(datos)

'Anio' · 'ID' · 'NombreOficina' · 'UnidadesExpuestas' · 'NombreSubdireccion' · 'DescTipoVehiculo' ·
'TipoPersona' · 'Edad' · 'Sexo' · 'DescMarcaVehiculo' · 'DescCarroceriaVehiculo' · 'ModeloVehiculo' ·
'DescUsoVehiculo' · 'PrimaNetaPropiaSinCoaseguro' · 'MontoOcurrido' · 'NumSiniestros' · 'signo' · 'FrecObs' ·
'SevObs' · 'Edadx'
```

Separando la muestra en entrenamiento y prueba

```
In [313... set.seed(1)
entrenamiento = sample(1:49608, (49608-10000))
prueba = c(1:49608)[-entrenamiento]
```

```
In [621... regFrec = glmmTMB(FrecObs ~ log(ModeloVehiculo)*TipoPersona + log(Anio) + HONDA + TOYOTA,
                    family=ziGamma(link="log"),
                    ziformula= ~ log(Edad) * TipoPersona + log(ModeloVehiculo) + log(Anio)
                    data= datos[entrenamiento,])
```

Family: Gamma ( log )  
Formula:  
FrecObs ~ log(ModeloVehiculo) \* TipoPersona + log(Anio) + HONDA + TOYOTA  
Zero inflation:  
~log(Edad) \* TipoPersona + log(ModeloVehiculo) + log(Anio) + HONDA + TOYOTA  
Data: datos[entrenamiento, ]

AIC	BIC	logLik	deviance	df.resid
16877.2	17014.5	-8422.6	16845.2	39592

Dispersion estimate for Gamma family (sigma^2): 0.461

Conditional model:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	0.21573	0.78337	0.275	0.783022
log(ModeloVehiculo)	0.14701	0.20254	0.726	0.467931
TipoPersonaMoral	5.05554	2.11675	2.388	0.016924 *
log(Anio)	0.17304	0.03159	5.478	4.31e-08 ***
HONDA	-0.27089	0.08060	-3.361	0.000777 ***
TOYOTA	0.11331	0.06077	1.865	0.062227 .
log(ModeloVehiculo):TipoPersonaMoral	-1.30850	0.53905	-2.427	0.015207 *

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Zero-inflation model:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	9.39775	1.14689	8.194	2.52e-16 ***
log(Edad)	0.52640	0.10682	4.928	8.32e-07 ***
TipoPersonaMoral	1.50478	0.51685	2.911	0.00360 **
log(ModeloVehiculo)	-2.19160	0.26991	-8.120	4.67e-16 ***
log(Anio)	0.38369	0.04585	8.368	< 2e-16 ***
HONDA	0.28350	0.12048	2.353	0.01861 *
TOYOTA	-0.29096	0.09152	-3.179	0.00148 **
log(Edad):TipoPersonaMoral	-0.32118	0.15145	-2.121	0.03395 *

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

## Modelo de la Severidad

```
In [606... regSevObs = glmmTMB(SevObs ~ log(ModeloVehiculo)* log(Anio) + log(Edad) + TipoPersona,
                     family=ziGamma(link="log"),
                     ziformula= ~ log(Edad) * TipoPersona + log(ModeloVehiculo) + log(Anio)
                     data= datos[entrenamiento,])
```

Family: Gamma ( log )  
Formula:  
SevObs ~ log(ModeloVehiculo) \* log(Anio) + log(Edad) + TipoPersona  
Zero inflation:

```
~log(Edad) * TipoPersona + log(ModeloVehiculo) + log(Anio) + HONDA + TOYOTA
Data: datos[entrenamiento, ]
```

AIC	BIC	logLik	deviance	df.resid
36357.9	36486.7	-18163.9	36327.9	39593

Dispersion estimate for Gamma family (sigma^2): 1.7

Conditional model:

	Estimate	Std. Error	z value	Pr(> z )	
(Intercept)	-11.8335	2.4279	-4.874	1.09e-06	***
log(ModeloVehiculo)	5.9832	0.6318	9.470	< 2e-16	***
log(Anio)	5.2934	2.1079	2.511	0.01203	*
log(Edad)	-0.2956	0.1066	-2.772	0.00557	**
TipoPersonaMoral	-0.3752	0.1476	-2.542	0.01103	*
log(ModeloVehiculo):log(Anio)	-1.4586	0.5435	-2.684	0.00728	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Zero-inflation model:

	Estimate	Std. Error	z value	Pr(> z )	
(Intercept)	8.57042	1.21444	7.057	1.70e-12	***
log(Edad)	0.56292	0.11448	4.917	8.77e-07	***
TipoPersonaMoral	1.44047	0.55103	2.614	0.008946	**
log(ModeloVehiculo)	-1.95920	0.28541	-6.865	6.67e-12	***
log(Anio)	0.33200	0.04956	6.700	2.09e-11	***
HONDA	0.29096	0.13090	2.223	0.026228	*
TOYOTA	-0.36231	0.09583	-3.781	0.000156	***
log(Edad):TipoPersonaMoral	-0.29122	0.16178	-1.800	0.071849	.

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

## Bondad de Ajuste

```
In [ ]: summary(regFrec)
```

```
In [ ]: summary(regSevObs)
```

```
In [615... FrecP = predict(regFrec,datos[entrenamiento,], type = "response")
SevP = predict(regSevObs,datos[entrenamiento,], type = "response")
```

```
In [616... summary(lm(datos$FrecObs[entrenamiento]~FrecP + 0))
```

Call:  
lm(formula = datos\$FrecObs[entrenamiento] ~ FrecP + 0)

Residuals:

Min	1Q	Median	3Q	Max
-0.410	-0.107	-0.088	-0.068	33.072

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
FrecP	0.99818	0.03674	27.17	<2e-16	***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.696 on 39607 degrees of freedom  
Multiple R-squared: 0.0183, Adjusted R-squared: 0.01827  
F-statistic: 738.3 on 1 and 39607 DF, p-value: < 2.2e-16

```
In [617... summary(lm(datos$SevObs[entrenamiento]~SevP + 0))
```

Call:  
lm(formula = datos\$SevObs[entrenamiento] ~ SevP + 0)

```
Residuals:
    Min       1Q   Median       3Q      Max
-4824    -857    -543    -293   903089

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
SevP    0.9676     0.0595   16.26  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10230 on 39607 degrees of freedom
Multiple R-squared:  0.006633, Adjusted R-squared:  0.006608
F-statistic: 264.5 on 1 and 39607 DF, p-value: < 2.2e-16
```

## Validación cruzada

In [607...

```
FrecP = predict(regFrec,datos[prueba,], type = "response")
SevP = predict(regSevObs,datos[prueba,], type = "response")
```

In [609...

```
summary(lm(datos$FrecObs[prueba]~FrecP + 0))
```

```
Call:
lm(formula = datos$FrecObs[prueba] ~ FrecP + 0)

Residuals:
    Min       1Q   Median       3Q      Max
-0.2373 -0.0997 -0.0817 -0.0635 12.3131

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
FrecP    0.93619     0.06347   14.75  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6014 on 9999 degrees of freedom
Multiple R-squared:  0.0213, Adjusted R-squared:  0.0212
F-statistic: 217.6 on 1 and 9999 DF, p-value: < 2.2e-16
```

In [611...

```
summary(lm(datos$SevObs[prueba]~SevP + 0))
```

```
Call:
lm(formula = datos$SevObs[prueba] ~ SevP + 0)

Residuals:
    Min       1Q   Median       3Q      Max
-2981    -504    -321    -172   302617

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
SevP    0.57983     0.07949   7.295 3.22e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6804 on 9999 degrees of freedom
Multiple R-squared:  0.005294, Adjusted R-squared:  0.005194
F-statistic: 53.21 on 1 and 9999 DF, p-value: 3.219e-13
```

## Predicción de todas las observaciones

In [612...

```
FreqT = predict(regFrec,datos, type = "response")
SevT = predict(regSevObs,datos, type = "response")
PrimaEstimada = FreqT*SevT
datos$Prima = Prima
```

## Exportando los resultados



```
In [628... write.csv(datos, file = "datos2.csv")
```

# Conclusiones

Se expusieron dos modelos Gamma - Cero inflado con interacciones para la Frecuencia y Severidad.

- Se identificaron como variables correlacionadas positivamente con el siniestro a: Edad, Año, Que el vehiculo sea HONDA y Ser persona Moral (siendo la más relevante la última).
- Se identificaron como variables correlacionadas negativamente con el siniestro a: ModeloVehiculo, Que el vehiculo sea Toyota y la interacción entre ser persona moral y la edad (siendo el modelo el aspecto más relevante).
- En validación cruzada se comprobo que el modelo no tiene mucha presición (se logra explicar al rededor de un 15% de la variablilidad de la prima), pero es un modelo interpretable, por ejemplo:
  - Para la parte de la regresión logistica del modelo de severidad, un incremento de un 1\% en el valor del año, esta asociado a un incremento del 139\% en el momio del evento (ya que  $\exp(0.332) \sim 1.3937$ ).